
基于强化学习的 Beer Game 库存订货控制

魏知原¹ 孙涌畅¹ 首雨欣¹

Abstract

本报告主要做的是 Beer Game 环境下的库存订货实验。我们把其中一个企业作为学习对象，尝试用几种强化学习算法来决定每一步应该订多少货。实验中先比较了一维订货动作下的 DQN、Double DQN 和 PPO，之后又把动作扩展成三维订单向量，比较 High-Dim DQN、High-Dim Double DQN 和 High-Dim PPO。单次主实验中，标准动作 PPO 的测试收益最高，为 627.90，需求满足率为 0.934；在高维动作空间中，High-Dim PPO 的测试收益为 406.63，也比另外两个高维 DQN 方法更好。由于一次实验可能受到随机性的影响，我们又对高维动作实验补充了 3 组 seed 的控制实验。在这个设置下，High-Dim PPO 的平均测试收益为 407.18 ± 21.33 ，高于 High-Dim DQN 的 339.91 ± 18.37 和 High-Dim Double DQN 的 306.04 ± 46.72 。从这些结果看，PPO 在本项目的环境里表现相对更稳定，所以后面主要把 High-Dim PPO 作为高维订单实验的代表方法。

1. 引言

Beer Game 是供应链管理课程中经常出现的一个例子。它的大致过程是：几个企业排成一条供应链，下游企业面对市场需求，上游企业根据下游企业的订单来补货。每个企业都要决定自己订多少货。如果订得太少，可能会缺货；如果订得太多，又会带来库存成本。因此这个问题看起来简单，但实际做决

策时并不容易。

课程提供了一个基础的 Beer Game 环境，也给出了随机策略接口。本项目中，我们选择企业 1 作为需要训练的智能体，其他企业用比较简单的 base-stock 策略。这样可以先把问题简化成单智能体强化学习问题。我们从 DQN baseline 做起，然后加入 Double DQN 和 PPO。除此之外，我们还把原来的一维订货量扩展成三维订单向量，想看看动作空间变复杂以后，不同算法的效果会有什么变化。

本报告把目前已经完成的实验结果放在一起比较。我们主要关心三个问题：第一，在普通的一维动作空间里，哪个算法效果更好；第二，把动作改成三维向量以后，学习难度是不是会变大；第三，在高维动作空间中，PPO 是否比 DQN 类方法更适合这个任务。

2. 环境与任务

实验环境中一共有 $N = 3$ 个企业。企业 0 直接面对外部市场需求，企业 1 是本项目训练的学习企业，企业 2 是上游企业。每个 episode 长度为 100 步。外部需求服从泊松分布：

$$D_t \sim \text{Poisson}(10). \quad (1)$$

每个企业能看到的状态比较简单，主要包括订单量、已经满足的需求量和当前库存：

$$s_{i,t} = [q_{i,t}, d_{i,t}, I_{i,t}]. \quad (2)$$

库存的变化按照下面的公式计算：

$$I_{i,t+1} = I_{i,t} + q_{i,t} - d_{i,t}. \quad (3)$$

也就是说，当前库存加上订货量，再减去满足的需求量，就是下一步库存。

¹ 北京大学信息科学技术学院，多智能体系统课程项目。

奖励函数由销售收入、采购成本、库存成本和缺货惩罚组成：

$$r_{i,t} = p_i d_{i,t} - p_{i+1} q_{i,t} - h I_{i,t} - c \max(0, D_{i,t} - d_{i,t}). \quad (4)$$

实验中价格设置为 $[10, 9, 8]$ ，库存持有成本 $h = 0.5$ ，缺货惩罚 $c = 2.0$ ，初始库存为 100。这个奖励函数的意思是，企业既要多卖货，也要控制订货和库存成本。

3. 算法与动作空间

3.1. 标准动作算法

在标准动作空间中，学习企业每一步只需要选择一个订货量，即 $a_t \in \{1, \dots, 20\}$ 。DQN 的做法是用神经网络估计每个动作的 Q 值，然后选择看起来收益比较高的动作。Double DQN 和 DQN 比较接近，只是在计算目标 Q 值时把动作选择和动作评估分开，希望减少 DQN 中可能出现的过估计问题。PPO 的思路不太一样，它直接学习一个随机策略，也就是给每个动作一个概率，再根据采样到的动作进行更新。本项目中 PPO 使用 actor-critic 网络、GAE 和 clipped objective，学习率为 10^{-4} ，clip range 为 0.15，entropy coefficient 为 0.03，reward scaling 为 0.01。

3.2. 高维动作算法

为了让订货动作稍微复杂一些，我们把一维订货量改成三维订单向量。每个通道可以选择 $\{0, 5, 10, 15, 20\}$ 中的一个值，同时要求三个通道的总订货量在 5 到 20 之间。去掉不满足条件的组合之后，一共有 34 个合法动作。环境中还给三个通道设置了不同的成本系数 $[1.0, 1.1, 1.25]$ ，所以智能体不仅要决定订多少，还要决定从哪个通道订。

在实现上，High-Dim DQN 和 High-Dim Double DQN 仍然是对每个离散动作学习 Q 值，只不过动作从原来 20 个标量变成了 34 个向量组合。High-Dim PPO 则把这 34 个组合作为分类策略的类别，先采样一个类别，再把它转换回具体的三维订单向量。

Table 1. 标准一维动作空间下 20 个测试 episode 的结果。

指标	DQN	Double DQN	PPO
平均收益	611.68	611.88	627.90
收益标准差	60.96	48.61	39.30
平均库存	18.04	16.69	17.41
平均订货量	8.63	8.20	8.45
需求满足率	0.937	0.917	0.934

这种做法实现起来比较直接，也方便和 DQN 对齐。不过它也有明显缺点：比如 $(5, 5, 0)$ 和 $(5, 0, 5)$ 其实很相似，但在模型看来只是两个普通的类别，没有直接体现出它们之间的关系。所以高维动作实验的难度会更大一些，算法需要在更多组合动作中找到合适的订货方式。

4. 实验设计

所有实验使用 Hydra 配置，输出保存在 `results/<algorithm>/<timestamp>/` 下，包括模型、训练分数、测试分数、测试轨迹和 `summary.json`。单次主实验使用当前仓库中最新可用的运行结果。标准 DQN、Double DQN、PPO，以及高维 DQN、高维 Double DQN、高维 PPO 都训练 2000 个 episode，并测试 20 个 episode。

不过，只看一次运行可能不太稳。不同算法使用的 seed offset 不完全一样，而且训练过程中消耗随机数的方式也不同，所以测试时遇到的需求序列可能不完全一致。为了让高维动作实验的比较更公平，我们又做了一个控制实验：对 High-Dim DQN、High-Dim Double DQN 和 High-Dim PPO 使用相同的 seed offset $\{0, 100, 200\}$ ，每组训练 2000 个 episode，并在测试前重置评估随机流。这样同一个 seed 下，不同算法面对的是相同的测试需求序列。

5. 单次主实验结果

从 Table 1 可以看到，在标准动作空间里，三个算法的平均收益其实差距不算特别大，但 PPO 最高，为 627.90，而且收益标准差最低。DQN 的需求满足率最高，达到 0.937，不过它的平均收益没有 PPO

Table 2. 三维订单向量动作空间下 20 个测试 episode 的结果。

指标	HD DQN	HD Double DQN	HD PPO
平均收益	357.75	299.50	406.63
收益标准差	100.91	104.83	74.12
平均库存	21.73	20.54	21.51
平均订货量	8.43	8.06	8.42
需求满足率	0.917	0.904	0.930




Figure 1. 单次主实验的测试收益对比。

高。这说明在这个环境里，并不是满足越多需求就一定收益越高，因为多订货也会带来采购成本和库存成本。Double DQN 的结果和 DQN 很接近，平均收益只略高一点，但方差更低。

Table 2 是高维动作空间的结果。可以看出，高维动作下所有方法的收益都比标准动作低，说明三维订单向量确实让问题变难了。在三种高维方法中，High-Dim PPO 的平均收益最高，为 406.63，而且标准差最小。High-Dim DQN 的收益为 357.75，High-Dim Double DQN 只有 299.50。从这个结果看，PPO 在高维动作空间里表现得更稳定一些。

Figure 1 中也能看到类似结论：标准动作空间下 PPO 的测试收益最高，高维动作空间中也是 High-Dim PPO 更好。Figure 2 展示了训练过程。相比标准动作方法，高维动作方法在训练初期的收益更低，波动也更明显，这和动作空间变复杂是符合预期的。




Figure 2. 单次主实验的训练收益移动平均曲线。

6. 控制实验结果

Table 3. 高维动作控制实验。均值和标准差按 3 个训练 seed 统计；每个 seed 的测试均值来自 20 个 episode。

方法	平均收益	满足率	库存	订货
HD PPO	407.18±21.33	0.946	22.25	8.43
HD DQN	339.91±18.37	0.934	22.76	8.32
HD Double DQN	306.04±46.72	0.938	23.07	8.35




Figure 3. 高维动作 3-seed 控制实验的平均测试收益。

为了进一步确认高维动作下的结果，我们做了 3 个 seed 的控制实验。Table 3 和 Figure 3 中，High-Dim PPO 的平均收益为 407.18 ± 21.33 ，仍然高于 High-Dim DQN 和 High-Dim Double DQN。High-Dim DQN 的平均收益为 339.91 ± 18.37 ，High-Dim

Double DQN 为 306.04 ± 46.72 。可以看到，Double DQN 在这里并没有带来提升，反而波动更大。表现最好的一次 High-Dim PPO 来自 seed offset 200，测试均值达到 424.95，需求满足率为 0.949。因此我们把这组结果作为高维动作实验中比较有代表性的结果。

7. 讨论

从实验结果看，标准一维动作策略的收益仍然比高维动作策略更高。这个结果一开始有点出乎预期，因为高维动作看起来表达能力更强，可以选择不同通道的订货组合。但后来分析后发现，当前实现只是把所有合法向量枚举成 34 个类别，模型并不知道这些动作之间有什么联系。因此动作变多以后，学习难度也变大了。

在高维动作实验中，PPO 的表现相对最好。一个可能原因是 PPO 本身是随机策略，并且使用了熵正则，所以训练过程中会持续探索不同的订单组合。而 DQN 类方法主要依赖 Q 值估计，如果动作数量变多，Q 值估计的噪声可能会影响动作选择。尤其是 High-Dim Double DQN，在本实验中没有比 High-Dim DQN 更好，说明 Double DQN 的改进在这个设置下不一定总是有效。

标准动作实验还说明，收益和需求满足率不是完全一致的指标。比如 DQN 的需求满足率略高于 PPO，但平均收益反而低一些。这说明库存控制不能只看是否满足需求，还要同时考虑采购成本和库存成本。如果后续继续改进高维动作方法，可能需要让模型更好地利用订单通道之间的结构，比如让策略分别决定每个通道的订货量，而不是直接在 34 个完整组合中选择。

8. 结论

本项目比较了 Beer Game 环境下几种强化学习订货策略。实验结果显示，在标准一维动作空间中，PPO 的平均收益最高，收益波动也最小。在三维订单向量的高维动作空间中，High-Dim PPO 也比 High-Dim DQN 和 High-Dim Double DQN 表现更好。虽然高

维动作空间理论上提供了更灵活的订货方式，但当前简单枚举动作的实现会增加学习难度，因此总体收益低于标准动作实验。综合来看，PPO 是本项目中比较合适的方法，后续如果继续做，可以重点改进高维动作空间的建模方式。