

基于强化学习的 Beer Game 库存订货控制

Anonymous Authors¹

Abstract

本文研究 Beer Game 供应链环境中的单智能体库存订货控制问题。项目实现并比较了标准一维订货动作下的 DQN、Double DQN、PPO，以及三维订单向量动作空间下的 High-Dim DQN、High-Dim Double DQN 和 High-Dim PPO。完整单次实验显示，标准动作 PPO 取得最高测试收益 627.90，同时需求满足率达到 0.934；高维动作实验中，High-Dim PPO 取得最高测试收益 406.63，明显优于 High-Dim DQN 和 High-Dim Double DQN。为避免单次运行和测试随机流带来的偶然性，我们进一步补充了 high-dim 控制实验，在相同训练 seed 列表和相同评估随机流下重复 3 组 seed。控制实验中，High-Dim PPO 的跨 seed 平均测试收益为 407.18 ± 21.33 ，高于 High-Dim DQN 的 339.91 ± 18.37 和 High-Dim Double DQN 的 306.04 ± 46.72 ；其中最佳 High-Dim PPO 运行达到 424.95。综合完整结果、稳定性和可解释性，本文最终选择 High-Dim PPO 作为高维订单空间的主要方法。

1. 引言

Beer Game 是供应链管理中的经典动态决策问题。多个企业按串行结构组成供应链，下游企业面对随

¹Anonymous Institution, Anonymous City, Anonymous Region, Anonymous Country. AUTHORERR: Missing \icmlcorrespondingauthor.

机市场需求，上游企业根据下游订单进行补货。企业的订货决策会影响库存持有成本、缺货惩罚和采购成本，短期看似合理的订货行为可能导致长期利润下降或库存波动放大。

课程代码给出了基础 Beer Game 环境和随机策略接口。本项目将企业 1 作为学习智能体，其余企业采用 base-stock 启发式策略，从而把问题化为单智能体强化学习。我们从 DQN baseline 出发，加入 Double DQN 和 PPO，并进一步把一维订货量扩展为三维订单向量，用于研究更复杂的高维动作空间。

本文重新整理当前完整实验，而不是只报告局部结果。主要问题包括：标准动作下哪个算法最好；高维动作是否显著增加学习难度；在 high-dim 场景下，PPO 是否比 DQN 类方法更适合；最终应选择哪组实验写入报告。

2. 环境与任务

实验环境包含 $N = 3$ 个企业。企业 0 接近外部市场，企业 1 是学习企业，企业 2 是上游企业。每个 episode 长度为 100 步，外部需求服从

$$D_t \sim \text{Poisson}(10). \quad (1)$$

企业局部观测由自身订单量、已满足需求和库存组成：

$$s_{i,t} = [q_{i,t}, d_{i,t}, I_{i,t}]. \quad (2)$$

库存更新为

$$I_{i,t+1} = I_{i,t} + q_{i,t} - d_{i,t}. \quad (3)$$

即时奖励由销售收入、采购成本、库存持有成本和缺货惩罚构成：

$$r_{i,t} = p_i d_{i,t} - p_{i+1} q_{i,t} - h I_{i,t} - c \max(0, D_{i,t} - d_{i,t}). \quad (4)$$

实验中价格为 $[10, 9, 8]$ ，库存持有成本 $h = 0.5$ ，缺货惩罚 $c = 2.0$ ，初始库存为 100。

3. 算法与动作空间

3.1. 标准动作算法

标准动作空间中，学习企业每步选择 $a_t \in \{1, \dots, 20\}$ 。DQN 使用神经网络近似 $Q(s, a)$ ，并通过 replay buffer 和 target network 训练。Double DQN 用在线网络选择下一步动作，用目标网络评估该动作价值，从而缓解 DQN 的过估计问题。PPO 使用 actor-critic 网络、GAE 和 clipped policy objective 直接优化随机策略，当前配置使用学习率 10^{-4} 、clip range 0.15、entropy coefficient 0.03 和 reward scaling 0.01。

3.2. 高维动作算法

高维动作空间把一维订货量扩展为三维订单向量。每个通道可选 $\{0, 5, 10, 15, 20\}$ ，总订货量限制在 5 到 20 之间。过滤非法组合后共有 34 个离散向量动作。环境使用通道成本系数 $[1.0, 1.1, 1.25]$ 计算采购成本。High-Dim DQN 和 High-Dim Double DQN 对 34 个组合动作学习 Q 值；High-Dim PPO 则把组合动作作为 categorical policy 的类别，采样后映射回订单向量。

这种枚举式 high-dim 设计便于与 DQN 对齐，但也带来明显困难：相近的订单向量被当作互不相关的类别，算法没有显式利用“总订货量相近”或“通道替换相近”等结构信息。因此 high-dim 实验既是动作空间扩展，也是对探索和策略优化能力的压力测试。

4. 实验设计

所有实验使用 Hydra 配置，输出保存到 `results/<algorithm>/<timestamp>/`，包含模型、训练分数、测试分数、测试轨迹和 `summary.json`。完整单次主结果采用当前仓库中最新可用运行：标准 DQN、Double DQN、PPO 以及 high-dim DQN、high-dim Double DQN、high-dim PPO 均训练 2000

Table 1. 标准一维动作空间下 20 个测试 episode 的结果。

指标	DQN	Double DQN	PPO
平均收益	611.68	611.88	627.90
收益标准差	60.96	48.61	39.30
平均库存	18.04	16.69	17.41
平均订货量	8.63	8.20	8.45
需求满足率	0.937	0.917	0.934

Table 2. 三维订单向量动作空间下 20 个测试 episode 的结果。

指标	HD DQN	HD Double DQN	HD PPO
平均收益	357.75	299.50	406.63
收益标准差	100.91	104.83	74.12
平均库存	21.73	20.54	21.51
平均订货量	8.43	8.06	8.42
需求满足率	0.917	0.904	0.930

个 episode，并测试 20 个 episode。

单次运行仍然存在随机性问题。不同算法的训练 seed offset 不同，且训练阶段消耗随机数数量不同，会导致测试需求序列不完全一致。因此我们补充 high-dim 控制实验：对 High-Dim DQN、High-Dim Double DQN 和 High-Dim PPO 使用相同 seed offset $\{0, 100, 200\}$ ，每组训练 2000 个 episode，并在测试前重置评估随机流。这样同一 seed 下的不同算法面对相同测试需求序列，比较更干净。

5. 完整单次实验结果

Table 1 显示，在标准动作空间中，PPO 的平均测试收益最高，为 627.90，同时收益标准差最低，为 39.30。DQN 的需求满足率略高，但其收益低于 PPO，说明更高服务水平并不一定对应更高利润，因为库存和采购成本也会进入奖励函数。Double DQN 相比 DQN 降低了方差和库存，但平均收益几乎持平。

Table 2 显示，在高维订单空间中，High-Dim PPO 是单次完整实验中表现最好的方法，平均收益 406.63，




Figure 1. 完整单次实验的测试收益对比。图中包含标准动作和 high-dim 动作下的六个算法。




Figure 2. 完整单次实验的训练收益移动平均曲线。High-dim 方法早期负收益更大，说明组合动作空间增加了探索难度。

方差也最低。相比之下，High-Dim DQN 平均收益为 357.75，High-Dim Double DQN 为 299.50。该结果说明，在当前枚举式向量动作空间中，直接优化随机策略的 PPO 比基于 Q 值的 off-policy 方法更稳。

Figure 1 从图形上汇总了六个算法的测试收益，标准动作 PPO 最高，高维动作中 High-Dim PPO 最高。Figure 2 展示了训练过程，标准动作方法整体更快进入稳定收益区间，而 high-dim 方法早期探索成本更高。

6. 控制实验结果

Table 3. High-dim 控制实验。均值和标准差按 3 个训练 seed 统计；每个 seed 的测试均值来自 20 个 episode。

方法	平均收益	满足率	库存	订货
HD PPO	407.18±21.33	0.946	22.25	8.43
HD DQN	339.91±18.37	0.934	22.76	8.32
HD Double DQN	306.04±46.72	0.938	23.07	8.35




Figure 3. High-dim 3-seed 控制实验平均测试收益。误差线表示不同训练 seed 之间的标准差。

Table 3 和 Figure 3 进一步验证了单次实验中的结论。High-Dim PPO 在 3 个训练 seed 上的平均收益为 407.18 ± 21.33 ，高于 High-Dim DQN 和 High-Dim Double DQN。High-Dim Double DQN 的跨 seed 标准差最大，说明它在当前 high-dim 设置下对随机初始化和探索路径更敏感。控制实验中最好的 High-Dim PPO 单次运行来自 seed offset 200，测试均值达到 424.95，需求满足率为 0.949。本文最终采用这组 High-Dim PPO 作为最优 high-dim 策略结果。

7. 讨论

从完整实验看，标准一维动作策略仍然比当前 high-dim 策略收益更高。原因不是高维订单一定无用，而是当前 high-dim 实现采用枚举式 categorical action，把 34 个向量组合视为互不相关的动作。这会增加探索难度，也使价值估计或策略优化更容易陷入局部策略。

在 high-dim 任务内部, PPO 是更合理的选择。第一, 单次完整实验中 High-Dim PPO 同时取得最高平均收益和最低收益方差。第二, 控制实验中 PPO 在 3 个 seed 上稳定领先。第三, PPO 的随机策略和熵正则有助于持续探索不同订单分配组合, 而 DQN 类方法在组合动作空间中更容易受到 Q 值估计噪声影响。

标准动作实验也给出一个启发: 收益最大化并不等同于单纯提高需求满足率。DQN 的标准动作满足率略高, 但 PPO 的收益更高且方差更小, 说明库存成本、采购成本和缺货惩罚之间存在平衡。未来若继续改进 high-dim 策略, 应考虑 factorized policy 或 autoregressive policy, 让策略按通道生成订单, 而不是把完整订单向量枚举为无结构类别。

8. 结论

本文完整比较了 Beer Game 中的标准动作和高维动作强化学习方法。标准动作空间下, PPO 取得最高平均测试收益 627.90, 并具有最低收益方差。高维订单空间下, High-Dim PPO 在单次完整实验中取得 406.63 的测试收益, 在 3-seed 控制实验中取得 407.18 ± 21.33 , 最佳控制运行达到 424.95, 均优于 High-Dim DQN 和 High-Dim Double DQN。因此, 本文最终选择 High-Dim PPO 作为高维订单空间的最佳实验结果和主要报告方法。