

■ 作业提交

- 最终提交内容需将以下几部分压缩打包命名为“学号+姓名”，提交截至时间：
 - 本学期**要毕业**的同学：**6月19日18:00**。
 - 本学期**不毕业**的同学：**7月1日18:00**。
- 1. **研究性报告**，pdf形式，中英文皆可，页数无强制要求但建议不少于3页，内容包括但不限于**研究方案、训练过程与参数、核心代码、实验结果分析、有趣的现象和启发**等，必要时可配图说明，同时注意参考文献的引用。
 - a) Latex版采用ICML2022模板 (<https://media.icml.cc/Conferences/ICML2022/Styles/icml2022.zip>)
 - b) Word版无给定模板，但总体要求采用双栏，单倍行距。

字体：英文为Time New Roman，中文为宋体。

字体大小：总标题为三号，章节标题为四号，其他内容为五号。
- 2. **完整代码和模型**，要求代码完整性，可复现性，并解释代码思路。训练好的策略网络模型需保存文件一并提交。
- 3. **demo展示**，完整的录屏展示，包括如何启动算法、最终结果等。

■ 评分说明

- 一、只要实验结果接近或超过给定基线，实验完整进行并合理分析，代码完整提交、过程符合学术诚信标准就可以获得大量基础分。
- 二、鼓励锻炼学术和创新性探索，不注重模型绝对性能。
- 三、实验报告占60%，代码和demo展示占40%。

啤酒厂供应链管理

助教：王驰原

北京大学计算机学院

邮箱：wang2021@stu.pku.edu.cn

微信：WCY_2610




■ 任务说明

作业目标：通过调节订单数量，实现啤酒游戏中某个企业的利润优化。

啤酒游戏是一种广泛使用的游戏，由多名玩家组成的串行供应链网络组成：

- 1.零售商：接收客户的订单并向批发商下订单；
- 2.中间商：接收上游企业的订单并向零售商下订单。



供应链中的企业根据观察到的订单和需求等信息，决策向上游订购的订单水平。

研究对象可以是链上企业（在作业代码中定义3个），可以选择一个企业进行利润优化，将其余看作是环境的一部分。

Beer game实验环境说明

订购和发货需要时间完成。每个订单从发起到收到货物需要1单位的时间来完成，也即 t 时刻向上游发出订单，在 $(t + 1)$ 时刻收到货物。

动作：程序表示企业的随机策略。设计合适的订购策略，替换对应企业动作。

```
while not done:
    # 假设每个企业的订单量是随机的，这里可以换成更复杂的策略
    actions = np.random.randint(1, 21, size=(num_firms, 1)) # 随机生成每个企业的订单量
```

观察：企业的观察包含3部分。当研究单个企业决策时，加载对应位置的企业观察。

```
"""
获取每个企业的观察信息，包括订单量、满足的需求量和库存。
每个企业的状态是独立的，包括自己观察的订单、需求和库存。
"""
return np.concatenate((self.orders, self.satisfied_demand, self.inventory), axis=1)
```

同学们选择1个企业研究即可。

Beer game实验环境说明

具体到每个企业 i :

$$s_{i,t} = [q_{i,t}, d_{i,t}, I_{i,t}]$$

状态的构成

- 订单量 q_t (企业向上游订购的产品数量)
- 满足的需求量 d_t (企业能够满足的市场需求)
- 库存水平 I_t (企业当前的库存水平)

其中:

- $q_{i,t}$ 是企业 i 在时间步 t 的订单量;
- $d_{i,t}$ 是企业 i 在时间步 t 满足的需求量;
- $I_{i,t}$ 是企业 i 在时间步 t 的库存水平。

环境转移

库存更新公式:

$$I_{i,t+1} = I_{i,t} + q_{i,t} - d_{i,t}$$

需求生成规则:

$$d_{1,t} = \min(D_t, I_{1,t}), \quad D_t \sim \text{Poisson}(\lambda)$$

$$d_{i,t} = \min(q_{i-1,t}, I_{i,t}), \quad \forall i \geq 2$$

其中, D_t 是最下游企业的市场需求。

奖励函数

企业的即时奖励:

$$r_{i,t} = p_i d_{i,t} - (p_{i+1} q_{i,t} \mathbf{1}_{i+1 < N}) - h I_{i,t} - c \max(0, D_t - d_{i,t})$$

其中:

- p_i 是企业 i 的售价;
- h 是库存持有成本;
- p_{i+1} 是企业 $i+1$ 的售价 (若 i 不是最上游企业);
- c 是损失销售成本。

■ 具体内容

- 目标：熟悉深度强化学习算法在Beergame环境训练测试和分析优化的完整流程，促进科学研究和工程实践。
- 具体包括但不限于以下几部分：

- **一、算法设计 (21分)**

已给出基线算法DQN，基于任意单智能体复现baseline算法（其余智能体可以参考管理学中的供应链策略，也可随机策略），用于优化自身利润；

- **二、提出创新 (14分)**

学习借鉴基线算法DQN，针对实验环境，**给出改进方案或设计新算法或拓展智能体数量**（或其他）

给出改进方案：如调节环境变量，改变demand分布，将订单空间拓展至高维，增加供应商数量等；

设计新算法：针对定义的具体目标，提高算法在特定任务上的能力；

改变RL决策的智能体数量：研究多智能体订货行为的关联。

分析改进原因或设计方案，不限于理论，网络结构，实现技巧等方面的改进和设计。对比训练曲线，保存不同算法的模型测试比较最终策略效果。结果图包括但不限于学习曲线，最终策略的订购行为比较。

■ 参考文献

- [1] Mnih, V., Kavukcuoglu, K., Silver, D. et al. Human-level control through deep reinforcement learning. Nature 518, 529–533 (2015). (DQN)
- [2] Schulman, J. , et al. "Proximal Policy Optimization Algorithms." (2017). (PPO)
- [3] Haarnoja, T. , et al. "Soft Actor-Critic Algorithms and Applications.", arXiv.1812.05905. 2018. (SAC)

2人合作推箱子

助教：王驰原

北京大学计算机学院




邮箱：wang2021@stu.pku.edu.cn

微信：WCY_2610



■ 实验环境

作业目标：通过控制2个小人，将2D地图里的箱子推到指定位置上。



链接: <https://github.com/mpSchrader/gym-sokoban>

■ 实验环境

观测空间类别

Type	State	Graphic	TinyWorld
Wall	Static		
Floor	Empty		
Box Target	Empty		
Box	Off Target		
Box	On Target		
Player	Off Target		
Player	On Target		

动作空间编码

Action (Player 1)	ID		Action (Player 2)	ID
No Operation	0			
P1: Push Up	1		P2: Push Up	9
P1: Push Down	2		P2: Push Down	10
P1: Push Left	3		P2: Push Left	11
P1: Push Right	4		P2: Push Right	12
P1: Move Up	5		P2: Move Up	13
P1: Move Down	6		P2: Move Down	14
P1: Move Left	7		P2: Move Left	15
P1: Move Right	8		P2: Move Right	16

■ 实验环境

Room Id: 环境编号, 在env.make时使用




Grid-Size: 实际地图的尺寸, 用于逻辑判断

Pixels: 观测地图的像素大小, 表示实际输入

#Boxes: 需要完成的箱子数量, 复杂度越高

2人合作推箱子环境共6种不同版本, 编号为v0至v5, 注意:

- (1) 每轮无强制要求某个agent行动
- (2) 可以用单智能体算法进行求解
- (3) 奖励为双人共享
- (4) 多智能体算法考虑信用分配

Room Id	Grid-Size	Pixels	#Boxes	Example
TwoPlayer-Sokoban-v0	7x7	160x160	2	
TwoPlayer-Sokoban-v1	7x7	160x160	3	
TwoPlayer-Sokoban-v2	10x10	112x112	3	

■ 基准算法

1. Heterogeneous-Agent Soft Actor-Critic (**HASAC**)

参考代码: <https://github.com/PKU-MARL/HARL>

参考文献: <https://arxiv.org/abs/2306.10715>

2. Heterogeneous-Agent Proximal Policy Optimisation (**HAPPO**)

参考代码: <https://github.com/PKU-MARL/HARL>

参考文献: <https://arxiv.org/pdf/2109.11251>

3. 更多MARL算法可以参考: <https://github.com/PKU-MARL/HARL>



■ 具体内容

- 目标：熟悉（多智能体）深度强化学习算法在双人sokoban环境训练测试和分析优化的完整流程，促进科学研究和工程实践。

- 具体包括但不限于以下几部分：

- **一、算法设计（21分）**

可以使用HARL库代码，将双人sokoban环境部署到HARL源代码库内，并完成多智能体算法的训练、评估；也可以使用其他MARL算法code base或使用自行编写训练评估框架。

- **二、提出创新（14分）**

学习借鉴基线算法，针对实验环境，**给出改进方案或设计新算法**（或其他）

给出改进方案：如重构环境、增加箱子数量、修改游戏规则等；

设计新算法：针对定义的具体目标，提高算法在任务上的能力；

分析改进原因或设计方案，不限于理论，网络结构，实现技巧等方面的改进和设计。对比训练曲线，保存不同算法的模型测试比较最终策略效果。结果图包括但不限于学习曲线，最终策略的行为比较。

最优税收设计

助教：王驰原

北京大学计算机学院


邮箱：wang2021@stu.pku.edu.cn

微信：WCY_2610



实验环境

作业目标：求解一个具有大量家户和政府的经济体的均衡状态，寻找最优税制。



B Household' lifetime utility:

$$\max \mathbb{E}_0 \sum_{t=0}^{T_N} \beta^t \left(\frac{c_t^{1-\theta}}{1-\theta} - \frac{h_t^{1+\gamma}}{1+\gamma} \right)$$


Diagram illustrating household utility components and the effect of a wealth tax:

- saving consumption**: a_{t+1} (blue bar) and c_t (red bar). h_t no change.
- working hours**: h_t (red bar). a_{t+1}, c_t no change.

Effects of a wealth tax:

- For **saving consumption**: $a_{t+1} \downarrow$, $c_t \uparrow$. Current utility $\uparrow$, current wealth $\downarrow$.
- For **working hours**: a_{t+1}, c_t no change. Current utility $\downarrow$, current wealth $\uparrow$.

C Government (nonlinear tax)



Github链接: <https://github.com/jidiai/TaxAI>
ArXiv链接: <https://arxiv.org/abs/2309.16307>

■ 实验环境

家户智能体：

- (1) 观测空间：低维表示，个人财富水平、收入水平+经济体平均资本、平均收入以及平均劳动时间。
- (2) 动作空间：消费量、工作时长。
- (3) 奖励函数：CRRA消费正效用+Fisch劳动负效用

政府智能体：

- (1) 观测空间：低维表示，经济体平均资本、平均收入、平均劳动时间等公共信息，不包括家户私有信息。
- (2) 动作空间：税率。
- (3) 奖励函数：可选择的多项混合，包括福利、平等、效率、产出。

综合目标：

同时求解出家户和政府的最优策略，注意家户和政府是异构智能体，家户间为同构智能体。

■ 基准算法

Baselines	Years	Average Social Welfare	Per Capita GDP	Wealth Gini	Income Gini
Free market	1.0	2.9	$4.3e6$	0.79	0.39
GA	200.0	6.9	$1.2e7$	0.54	0.52
IPPO	162.7	1035.5	$8.4e6$	0.62	0.44
MADDPG	204.2	1344.6	$1.0e6$	0.61	0.58
MAPPO	274.5	3334.7	$7.3e6$	0.61	0.65
HAPPO	298.7	1986.0	$1.6e7$	0.52	0.54
HATRPO	300.0	1945.0	$1.7e7$	0.52	0.54
HAA2C	300.0	2113.3	$1.4e7$	0.51	0.53
BMFAC	292.8	3722.2	$2.8e6$	0.48	0.50

MARL算法可以参考: <https://github.com/PKU-MARL/HARL>

■ 具体内容

- 目标：熟悉多智能体深度强化学习算法在TaxAI环境训练测试和分析优化的完整流程，促进科学研究和工程实践。
- 具体包括但不限于以下几部分：

- **一、算法设计（21分）**

可以使用原代码库提供的MAPPO、MADDPG等算法进行直接实验；也可以使用HARL库代码，将TaxAI环境部署到HARL源代码库内，并完成多智能体算法的训练、评估；也可以使用其他MARL算法code base或使用自行编写训练评估框架。

- **二、提出创新（14分）**

学习借鉴基线算法，针对实验环境，**给出改进方案或设计新算法**

给出改进方案：改进TaxAI环境机制，例如可以考虑引入更丰富的冲击类型，新的经济部门例如财政、货币等，也可以增加政府观测维度（理论上政府需要观测完整分布才能知道最优税率）；

设计新算法：针对定义的具体目标，提高算法在任务上的能力，重点考察（1）如何处理大规模household问题（2）如何处理异构智能体问题（政府和家户形成了一个斯塔尔伯格博弈）；

分析改进原因或设计方案，不限于理论，网络结构，实现技巧等方面的改进和设计。对比训练曲线，保存不同算法的模型测试比较最终策略效果。结果图包括但不限于学习曲线，最终策略的行为比较。

胡闹厨房overcooked

助教：王驰原

北京大学计算机学院

邮箱：wang2021@stu.pku.edu.cn

微信：WCY_2610



实验环境

作业目标：控制两个智能体在给定时间内合作完成每个关卡的订单运送任务。



原始库： https://github.com/HumanCompatibleAI/overcooked_ai
新库（支持更好）： <https://github.com/Stanford-ILIAD/PantheonRL>

■ 实验环境

观测空间：游戏画面

动作空间：上下左右移动+停留+交互，共6种

奖励函数：完成订单有固定得分，完成其他任务也有附加分

```
rew_shaping_params = {  
    "PLACEMENT_IN_POT_REW": 3,  
    "DISH_PICKUP_REWARD": 3,  
    "SOUP_PICKUP_REWARD": 5,  
    "DISH_DISP_DISTANCE_REW": 0,  
    "POT_DISTANCE_REW": 0,  
    "SOUP_DISTANCE_REW": 0,  
}
```

■ 具体内容

- 目标：熟悉多智能体深度强化学习算法在overcooked环境训练测试和分析优化的完整流程，促进科学研究和工程实践。
- 具体包括但不限于以下几部分：

- **一、算法设计 (21分)**

可以使用原代码库提供的PPO、SAC、A2C、DQN等算法进行直接实验；也可以使用HARL库代码，将overcooked环境部署到HARL源代码库内，并完成多智能体算法的训练、评估；也可以使用其他MARL算法code base或使用自行编写训练评估框架。

- **二、提出创新 (14分)**

学习借鉴基线算法，针对实验环境，**给出改进方案或设计新算法**

给出改进方案：例如使用不同的reward shaping方式，对不同的中间任务增加奖励，观察是否能够提升算法性能，或者尝试不同的游戏参数设定，增加游戏难度；

设计新算法：尝试新的算法，例如一些经典的团队协作算法、多智能体算法等，重点考察（1）如何解决多智能体信用分配问题（2）能否在性能上超越基于单智能体轮流优化的基线算法。

分析改进原因或设计方案，不限于理论，网络结构，实现技巧等方面的改进和设计。对比训练曲线，保存不同算法的模型测试比较最终策略效果。结果图包括但不限于学习曲线，最终策略的行为比较。

■ 基准算法

1. Proximal Policy Optimization (**PPO**) <https://arxiv.org/abs/1707.06347>
2. Deep Q-network (**DQN**) <https://arxiv.org/abs/1312.5602>
3. Soft Actor-Critic (**SAC**) <https://arxiv.org/abs/1801.01290>
4. Other MARL algorithms <https://github.com/PKU-MARL/HARL>

多人仓储

助教：黄奕喆

北京大学智能学院


邮箱： szhyz@pku.edu.cn

微信：15989316391



■ 实验环境

作业目标：控制多个智能体，合作完成仓储取物的问题。



链接：<https://github.com/semitable/robotic-warehouse>

观测空间类别

Observation Space

The observation of an agent is partially observable and consists of a 3x3 (configurable) square centred on the agent. Inside this limited grid, all entities are observable:

- The location, the rotation and whether the agent is carrying a shelf.
- The location and rotation of other robots.
- Shelves and whether they are currently in the request queue.

动作空间

Action Space

In this simulation, robots have the following discrete action space:

$A = \{ \text{Turn Left, Turn Right, Forward, Load/Unload Shelf} \}$

The first three actions allow each robot only to rotate and move forward. Loading/Unloading only works when an agent is beneath a shelf on one of the predesignated locations.

■ 基准算法

1. Independent Actor-Critic (**IAC**)

2. Shared Network Actor-Critic (**SNAC**)

3. Shared Experience Actor-Critic (**SEAC**)

参考文献: <https://github.com/uoel-agents/seac/tree/master>

<https://proceedings.neurips.cc/paper/2020/file/7967cc8e3ab559e68cc944c44b1cf3e8-Paper.pdf>

■ 具体内容

- 目标：熟悉（多智能体）深度强化学习算法在RWARE环境训练测试和分析优化的完整流程，促进科学研究和工程实践。

- 具体包括以下几部分：

- **一、算法设计（21分）**

可以使用已有的仓库代码，实现IAC、SNAC、SEAC三个基线算法，并完成多智能体算法的训练、评估；也可以自行编写训练评估框架。请使用“rware-tiny-2ag-v2”和“rware-small-4ag-v2”进行测试。

- **二、提出创新（14分）**

学习借鉴基线算法，针对实验环境，**给出改进方案或设计新算法**（或其他）

给出改进方案：如修改训练方式、调整神经网络结构，增加新的损失函数等；

设计新算法：针对定义的具体目标，提高算法在任务上的能力；

分析改进原因或设计方案，不限于理论，网络结构，实现技巧等方面的改进和设计。对比训练曲线，保存不同算法的模型测试比较最终策略效果。结果图包括但不限于学习曲线，最终策略的行为比较。

2人*2队乒乓赛

助教：黄奕喆

北京大学智能学院


邮箱： szhyz@pku.edu.cn

微信：15989316391



■ 实验环境

作业目标：控制4个智能体，这4个智能体两两一队，进行桌面乒乓比赛。



链接：<https://ale.farama.org/multi-agent-environments/quadrapong/>

实验环境

观测空间类别

Import	<code>from pettingzoo.atari import quadrapong_v4</code>
Actions	Discrete
Parallel API	Yes
Manual Control	No
Agents	<code>agents= ['first_0', 'second_0', 'third_0', 'fourth_0']</code>
Agents	4
Action Shape	(1,)
Action Values	[0,5]
Observation Shape	(210, 160, 3)
Observation Values	(0,255)

动作空间编码

Value	Meaning	Value	Meaning	Value	Meaning
0	NOOP	1	FIRE	2	UP
3	RIGHT	4	LEFT	5	DOWN

■ 基准算法

1. Independent Proximal Policy Optimization (**IPPO**)

参考文献: <https://arxiv.org/abs/1707.06347>

2. Multi-Agent Proximal Policy Optimisation (**MAPPO**)

参考文献: <https://arxiv.org/abs/2103.01955>

3. Monotonic Value Function Factorisation (**QMIX**)

参考文献: <https://arxiv.org/pdf/1803.11485>

4. 更多MARL算法可以参考: <https://github.com/PKU-MARL/HARL> <https://cleanmarl-docs.readthedocs.io/en/latest/marl.html>

■ 具体内容

- 目标：熟悉（多智能体）深度强化学习算法在quadrapong环境训练测试和分析优化的完整流程，促进科学研究和工程实践。

- 具体包括以下几部分：

- **一、算法设计（21分）**

可以使用已有的仓库代码，实现IPPO、MAPPO、QMIX三个基线算法，并完成多智能体算法的训练、评估；也可以自行编写训练评估框架。环境中有两个队伍，可以将三种算法两两比较。

- **二、提出创新（14分）**

学习借鉴基线算法，针对实验环境，**给出改进方案**或**设计新算法**（或其他）

给出改进方案：如修改训练方式、调整神经网络结构，增加新的损失函数等；

设计新算法：针对定义的具体目标，提高算法在任务上的能力；

分析改进原因或设计方案，不限于理论，网络结构，实现技巧等方面的改进和设计。对比训练曲线，保存不同算法的模型测试比较最终策略效果。结果图包括但不限于学习曲线，最终策略的行为比较。

马尔可夫社会困境

助教：黄奕喆

北京大学智能学院


邮箱： szhyz@pku.edu.cn

微信：15989316391



■ 实验环境

作业目标：控制三个智能体，提升群体合作水平，提高群体奖励。



链接：<https://github.com/google-deepmind/meltingpot>

观测空间类别

动作空间

- Sprites are 8×8 pixels.
- The agents have a partial observability window of 11×11 sprites, offset so they see more in front than behind them. The agent sees 9 rows in front of itself, 1 row behind, and 5 columns to either side. A few substrates use smaller observation windows, noted in their respective sections.
- Thus in RGB pixels, the size of each observation is $88 \times 88 \times 3$. All agent architectures used here have RGB pixel representations as their input.
- Movement actions are: forward, backward, strafe left, strafe right, turn left, and turn right.

■ 基准算法

1. Independent RL (PPO或其他RL算法均可)

参考文献: <https://arxiv.org/abs/1707.06347>

2. Prosocial RL (即在Independent基础上共享奖励, PPO或其他RL算法均可)

参考文献: <https://arxiv.org/abs/1707.06347>

<https://arxiv.org/pdf/1709.02865>

<https://arxiv.org/pdf/2211.13746>

3. Inequity aversion (对奖励的特别处理方式, PPO或其他RL算法均可)

参考文献: <https://proceedings.neurips.cc/paper/2018/file/7fea637fd6d02b8f0adf6f7dc36aed93-Paper.pdf>

■ 具体内容

WARNING: 本题观测空间与状态空间较大，训练时长可能较长，请谨慎选择

- 目标：熟悉（多智能体）深度强化学习算法在Melting Pot - Allelopathic Harvest环境训练测试和分析优化的完整流程，促进科学研究和工程实践。

- 具体包括以下几部分：

- **一、算法设计（21分）**

可以使用已有的仓库代码，实现Independent, Prosocial, Inequity aversion三种多智能体任务中对于reward的处理方法（可以套用在任意RL算法中，请保持三组实验所用的RL算法一致），并完成多智能体算法的训练、评估；也可以自行编写训练评估框架。目标提升群体合作水平、群体奖励水平。

- **二、提出创新（14分）**

学习借鉴基线算法，针对实验环境，**给出改进方案或设计新算法**（或其他）

给出改进方案：如修改训练方式、调整神经网络结构，增加新的损失函数等，增加新的奖励处理方案；

设计新算法：针对定义的具体目标，提高算法在任务上的能力；

分析改进原因或设计方案，不限于理论，网络结构，实现技巧等方面的改进和设计。对比训练曲线，保存不同算法的模型测试比较最终策略效果。结果图包括但不限于学习曲线，最终策略的行为比较。